# UT 1 · Práctica 1

## Extracción de datos de fuentes diversas con Pandas

## Relación con el módulo

**RA 3** · *Gestiona y almacena datos facilitando la búsqueda de respuestas en grandes conjuntos de datos.*

| Criterio de evaluación | Cómo se trabaja en esta práctica |
|---|---|
| **a)** Se han extraído y almacenado datos de diversas fuentes, para ser tratados en distintos escenarios. *Criterio principal.* | Cuatro fuentes con cuatro formatos distintos (CSV, JSON, Excel y base de datos SQLite), guardadas en bruto en un área intermedia con un registro de su procedencia. |
| **c)** Se ha comprobado que la revolución digital exige poder almacenar y procesar ingentes cantidades de datos de distinto tipo y descubrir su valor. *En parte.* | Datos de tipos muy distintos (texto plano, datos semiestructurados, hoja de cálculo y base de datos relacional) y volúmenes que ya se notan: más de 70 000 viviendas vacacionales y 385 000 filas de ocupación hotelera. |
| **d)** Se han desarrollado sistemas de gestión, almacenamiento y procesamiento de grandes volúmenes de datos de manera eficiente y segura, teniendo en cuenta la normativa existente. *En parte.* | Elección de un formato de almacenamiento eficiente a partir de una comparación medida; base de datos abierta en modo solo lectura; licencias y condiciones de uso anotadas; base de datos simulada, sin datos de personas ni negocios reales. |

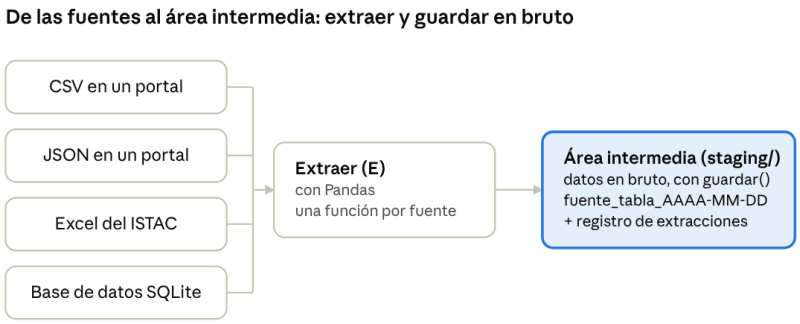
## Qué vas a hacer

Vas a reunir datos sobre **el alojamiento turístico en Canarias** desde cuatro fuentes, cada una en un formato distinto, y a guardarlos **tal como vienen** en una carpeta de tu Google Drive, anotando de dónde sale cada archivo. Es el primer paso de cualquier proyecto de datos: sin datos bien extraídos y localizados, no hay análisis posible.

Al terminar sabrás:

- Leer datos de un CSV y de un JSON publicados en internet, de una hoja de cálculo Excel y de una base de datos SQL.
- Extraer de una base de datos tanto una tabla completa como solo una parte, con una consulta.
- Guardarlos sin modificar en un **área intermedia** (`staging/`), con un nombre que diga qué son y cuándo se sacaron.
- Elegir y justificar el formato de almacenamiento (CSV, Parquet o JSON) midiendo cuánto ocupa y cuánto tarda cada uno.
- Llevar un **registro de extracciones** con la procedencia de cada archivo.
- Organizar tu código en funciones reutilizables.

Dentro de un proceso **ETL** (extraer, transformar, cargar), esta práctica corresponde a la **extracción**: sacar los datos de su origen y guardarlos en bruto en el área intermedia. Como en la arquitectura de *data warehouse* que hemos estudiado, el **área intermedia** es donde se dejan los datos recién extraídos, antes de transformarlos y cargarlos en el almacén: guardarlos ahí forma parte de la extracción. Aunque veas errores en los datos, **no los corriges**: los anotas.




Todo lo que extraigas acaba en `staging/` sin cambios, junto con el registro de su procedencia.

## Antes de empezar

Trabajarás en **Google Colab**, un servicio gratuito de Google que ejecuta cuadernos de Python en el navegador: no hay que instalar nada. Solo necesitas tu cuenta de Google del centro.

### Materiales del aula virtual

| Archivo | Qué es | Tamaño |
|---|---|---|
| `SPS_UT1_P1_extraccion_ALUMNADO.ipynb` | El cuaderno que vas a completar | 36 KB |
| `ocupacion_hotelera_istac.xlsx` | Ocupación hotelera por municipios del ISTAC (fuente 3) | 18 MB |
| `hoteles_reservas.db` | Base de datos simulada de reservas de una cadena hotelera (fuente 4) | 4,4 MB |

Las fuentes 1 y 2 no se descargan: el cuaderno las lee directamente de internet.

### Puesta en marcha

1. Entra en colab.research.google.com con tu cuenta del centro.
2. **Archivo → Subir cuaderno** y elige `SPS_UT1_P1_extraccion_ALUMNADO.ipynb`.
3. **Archivo → Guardar una copia en Drive**. Cambia el nombre a `SPS_UT1_P1_Apellido_Nombre.ipynb`. Si te saltas este paso, perderás tus cambios.
4. Ejecuta la **celda 0** (Mayús + Intro). Colab te pedirá permiso para acceder a tu Drive: acéptalo. Se crea la carpeta `Mi unidad/SPS_UT1_P1`.
5. Ejecuta la **celda 1**. Se crean dentro las carpetas `staging/` y `datos_profesora/`.
6. Sube `ocupacion_hotelera_istac.xlsx` y `hoteles_reservas.db` a `datos_profesora/`, sin cambiarles el nombre. Puedes hacerlo desde drive.google.com o desde el icono de carpeta de la barra izquierda de Colab.
7. Vuelve a ejecutar la celda 1: al final debe mostrar los dos archivos que has subido.

### Cinco cosas que hay que saber de Colab

| Quiero… | Cómo |
|---|---|
| Ejecutar una celda | Clic en ella y **Mayús + Intro**, o el botón ▶ |
| Ejecutar todo desde el principio | **Entorno de ejecución → Reiniciar y ejecutar todo** |
| Añadir una celda | **+ Código** o **+ Texto**, arriba |
| Ver los archivos | Icono de carpeta, en la barra izquierda |
| Entender un error | Lee la **última línea** del mensaje rojo: dice qué ha fallado |

Si cierras Colab y vuelves otro día, la memoria se borra: tienes que ejecutar de nuevo las celdas desde la 0. Los archivos de Drive, en cambio, se conservan.

## Tareas

El cuaderno te guía apartado por apartado. Las celdas marcadas con ✏ tienen huecos (`...` o `# TODO`) que debes completar. Sigue el orden de las tareas: con la fuente 1 subirás una vez al apartado 2 y, después, recorrerás el cuaderno de arriba abajo.

| Apartado | Fuente | Formato | Función de extracción | Qué guardas en `staging/` |
|---|---|---|---|---|
| 3 | Registro de establecimientos hoteleros (Gobierno de Canarias) | CSV por URL | `extraer_csv_url()` | Una tabla |
| 4 | Registro de viviendas vacacionales (Gobierno de Canarias) | JSON por URL | `extraer_json_url()` | El JSON original y una tabla |
| 5 | Ocupación hotelera por municipios (ISTAC) | Excel | `extraer_excel()` | La tabla, en CSV y en Parquet |
| 6 | Reservas de la Cadena Hotelera Atlántica (simulada) | Base de datos SQLite | `extraer_sql()` | Cada tabla completa y una extracción selectiva |

### Tarea 1 · Leer la fuente 1 (apartado 3, primera parte)

1. Completa la llamada a `pd.read_csv()` en `extraer_csv_url()`: separador `;`, codificación, `dtype=str` y `keep_default_na=False`.
2. Ejecuta la extracción y mira el resultado con `head()` e `info()`.
3. Anota **al menos tres** problemas de calidad que veas en los datos. No los corrijas.

Los datos ya están en memoria, en la variable `hoteles`, pero todavía no se han guardado: si cerraras Colab ahora, se perderían.

### Tarea 2 · Preparar el guardado (apartado 2)

Vuelve al apartado 2. Es la única vez que tendrás que subir en el cuaderno.

1. Completa `guardar()` para que escriba CSV y Parquet **sin el índice** de Pandas.
2. Completa `registrar()`: la fecha y hora de la extracción y el formato del archivo.
3. Ejecuta las dos celdas. Fíjate en la convención de nombres: `fuente_tabla_AAAA-MM-DD.ext`, por ejemplo `datoscanarias_hoteles_2026-10-21.parquet`.

### Tarea 3 · Guardar la fuente 1 (apartado 3, final)

1. Baja a la última celda de código del apartado 3.
2. Guarda la tabla `hoteles` en el formato que elijas y regístrala. La licencia está en la ficha del conjunto en datos.canarias.es.

A partir de aquí, sigue el cuaderno de arriba abajo: en cada fuente lees, observas, guardas y registras.

### Tarea 4 · JSON publicado en una URL (apartado 4)

1. Completa `extraer_json_url()`: convierte la respuesta en diccionario con `.json()` y la lista `result` en tabla con `pd.json_normalize()`.
2. Ejecuta la extracción y mira la estructura del JSON: sus claves, el número de registros y el primero de ellos.
3. Cuenta cuántas viviendas no tienen coordenadas y anota lo que observes. No lo corrijas.
4. Guarda y registra el JSON original y la tabla.

### Tarea 5 · Hoja de cálculo Excel (apartado 5)

1. Completa `extraer_excel()` con `pd.read_excel()`. La lectura tarda uno o dos minutos: es normal.
2. Mira las primeras filas y fíjate en los datos marcados como confidenciales. No los rellenes ni los borres.
3. Guarda la tabla **en CSV y en Parquet** y registra los dos archivos.
4. Ejecuta la comparación de formatos y apunta el tamaño y el tiempo de lectura del Excel, del CSV y del Parquet. Los usarás en la pregunta 2.

### Tarea 6 · Base de datos SQLite (apartado 6)

1. Consulta la lista de tablas y lee la tabla `acerca_de`.
2. **Extracción completa:** recorre todas las tablas y, para cada una, extrae `SELECT * FROM "<tabla>"`, guárdala y regístrala.
3. **Extracción selectiva:** completa la condición `WHERE` para extraer solo las reservas hechas desde el 1 de octubre de 2026.
4. Lee la nota final sobre las bases de datos en las empresas.

### Tarea 7 · Comprobación (apartado 7)

1. Ejecuta la comprobación del área intermedia.
2. Todas las líneas deben salir ✔ **correcto** (o *JSON original*). Si alguna sale ✘, revisa esa extracción.
3. Comprueba en Drive que `staging/` contiene tus archivos y `registro_extracciones.csv`.

## Preguntas de reflexión

Responde en las celdas de texto del apartado 8 del cuaderno: de 3 a 5 líneas cada una, con tus palabras y apoyándote en lo que has visto al ejecutar.

1. ¿Por qué guardamos los datos **en bruto**, sin limpiarlos, aunque veamos errores?
2. ¿Qué formato has elegido para guardar cada fuente (CSV, Parquet, JSON) y por qué? Usa los números de la comparación del apartado 5.
3. En el CSV de hoteles usamos `dtype=str` y `keep_default_na=False`. ¿Qué crees que pasaría sin ellos?
4. En la fuente 2 guardamos el JSON original **y además** la tabla. ¿Para qué sirve guardar los dos?
5. ¿Para qué sirven la fecha en el nombre del archivo y el registro de extracciones? Piensa en que los registros de hoteles y de viviendas vacacionales se actualizan a diario.
6. El registro de viviendas vacacionales se actualiza a diario. ¿Qué inconveniente tiene descargarlo entero cada día? ¿Qué ventaja tendría una API que te diera solo los cambios? ¿Qué parte de esta práctica se parece a esa idea?
7. Si mañana los archivos tuvieran que guardarse en otro sitio (otro servidor o un almacenamiento en la nube) en lugar de en `staging/`, ¿qué partes del cuaderno cambiarías?

## Entrega

Entrega dos archivos en la tarea del aula virtual. Fecha límite: *por fijar*.

1. El cuaderno **ejecutado de principio a fin**, con las salidas visibles: en Colab, **Entorno de ejecución → Reiniciar y ejecutar todo** y después **Archivo → Descargar → Descargar .ipynb**.
2. El archivo `registro_extracciones.csv` de tu carpeta `staging/`, que reúne la procedencia de todo lo que has extraído.

No hace falta entregar los demás archivos de `staging/`.

## Si algo falla

Lee siempre la última línea del mensaje de error: casi siempre dice qué pasa.

| Mensaje o síntoma | Qué significa | Qué hacer |
|---|---|---|
| `NameError: name 'pd' is not defined` (u otro nombre) | No has ejecutado una celda anterior, o Colab se ha reiniciado | **Reiniciar y ejecutar todo** |
| `FileNotFoundError: No encuentro ocupacion_hotelera_istac.xlsx…` (o `hoteles_reservas.db`) | El archivo no está en `datos_profesora/` o tiene otro nombre | Súbelo a esa carpeta con ese nombre exacto |
| `ValueError: Formato no soportado: Ellipsis` | Has dejado `formato=...` sin completar | Escribe `"csv"` o `"parquet"` |
| La celda del Excel lleva más de un minuto girando | Es normal: son casi 400 000 filas | Espera hasta que termine |
| Aviso en rosa `UserWarning: Workbook contains no default style` | El Excel no tiene estilos de formato | Nada: no es un error |
| Todo sale en una sola columna | El separador no es el correcto | Revisa `sep=`: en el CSV de hoteles es `;` |
| `UnicodeDecodeError` | La codificación no coincide con la del archivo | Revisa `encoding=` y anótalo en el registro |

| Mensaje o síntoma | Qué significa | Qué hacer |
|---|---|---|
| `HTTPError` o `ConnectionError` | El portal no responde o la dirección ha cambiado | Espera un minuto y repite; abre la URL en el navegador para comprobarla |
| `TypeError: 'ellipsis' object…` o `KeyError: 'result'` | Falta completar `datos = ...` en `extraer_json_url()` | Escribe `datos = respuesta.json()` |
| `sqlite3.OperationalError` | Error en la consulta SQL (falta una comilla, un nombre mal escrito…) | Revisa la consulta; los nombres de tabla y columna deben coincidir con los de la base de datos |

## Fuentes y licencias

- Establecimientos hoteleros inscritos en el Registro General Turístico de Canarias — Consejería de Turismo y Empleo, Gobierno de Canarias. CSV, actualización diaria. Uso según el aviso legal y condiciones de uso de datos.canarias.es.
- Establecimientos extrahoteleros de tipología vivienda vacacional inscritos en el Registro General Turístico de Canarias — misma Consejería. JSON, actualización diaria. Mismas condiciones de uso.
- Establecimientos abiertos, plazas, habitaciones ofertadas y tasas de ocupación de hoteles según categorías. Islas y municipios de Canarias por periodos — Instituto Canario de Estadística (ISTAC), conjunto C00065A_000001, versión 1.70, descargada el 21/10/2026. Uso según el aviso legal del ISTAC.
- `hoteles_reservas.db` — base de datos simulada de la *Cadena Hotelera Atlántica*, creada para esta práctica. Hoteles, clientes y reservas son ficticios; no corresponden a ningún negocio ni persona reales.